Algorithmique pour l'intelligence artificielle et l'étude des jeux

Chapitre 1 : Intelligence artificielle

Eric Brillaux
Lycée Théophile Gautier PC
2025 - 2026
Version : 4 février 2026

Prérequis de PCSI
▶

Programme officiel

Notions	Commentaires
Algorithme des k plus proches voisins avec distance euclidienne.	Matrice de confusion. Lien avec l'apprentissage supervisé.
Algorithme des k-moyennes.	Lien avec l'apprentissage non-supervisé. La démonstration de la convergence n'est pas au programme. On observe des convergences vers des minima locaux.
Mise en œuvre	
La connaissance dans le détail des algorithmes de cette section n'est pas un attendu du programme. Les étudiants acquièrent une familiarité avec les idées sous-jacentes qu'ils peuvent réinvestir dans des situations où les modélisations et les recommandations d'implémentation sont guidées, notamment dans leurs aspects arborescents.	

Sommaire

L'expression *intelligence artificielle* (IA) a été créée par les américains John McCarty et Marvin Lee Minsky en 1956. Cette époque est marquée par un forte enthousiasme dans le domaine. Les premières IA, comme Eliza, construite au MIT en 1965, étaient capable de dialoguer en anglais en reconstruisant des phrases toutes faites. Pourtant, les intelligences artificielles vraiment performantes ont mis du temps à émerger. À partir des années 80, des outils formels informatiques sont développer pour étudier l'IA : les réseaux de neurone, les algorithmes génératifs, etc. L'IA a réussi à supplanter l'humain dans certains jeux réputés réservés à l'intelligence humaine : citons la machine Deep Blue qui battit G. Kasparov aux échecs en 1997, ou encore la machine AlphoGo qui battit L. Sedol au jeu de go en 2016.

I Introduction **1**
I.A Apprentissage automatique 1
I.B Algorithmes de classement 3
II Apprentissage supervisé **3**
II.A Algorithme des k plus proches voisins 3
II.B Matrice de confusion 5
III Apprentissage non supervisé **6**
III.A Algorithme des k moyennes 6

I – Introduction

Définition 1.1

*L'**intelligence artificielle** désigne une machine capable de réaliser des tâches habituellement exécutées par des humains, qui nécessitent des capacités de raisonnement, de mémoire, et d'apprentissage,*

(a) Voitures autonomes

(b) Reconnaissance vocale

(c) Agent conversationnel

(d) Génération d'images artistiques

FIG. 1.1 – Quelques domaines d'applications de l'intelligence artificielle (IA). (a) Voitures autonomes. (b) Reconnaissance vocale. (c) Agent conversationnel. (d) Génération d'images artistiques.

I.A – Apprentissage automatique

Définition 1.2

*L'**apprentissage automatique** désigne une méthode qui permet à une IA d'apprendre à résoudre un problème sans jamais la programmer explicitement pour résoudre ce problème particulier.*

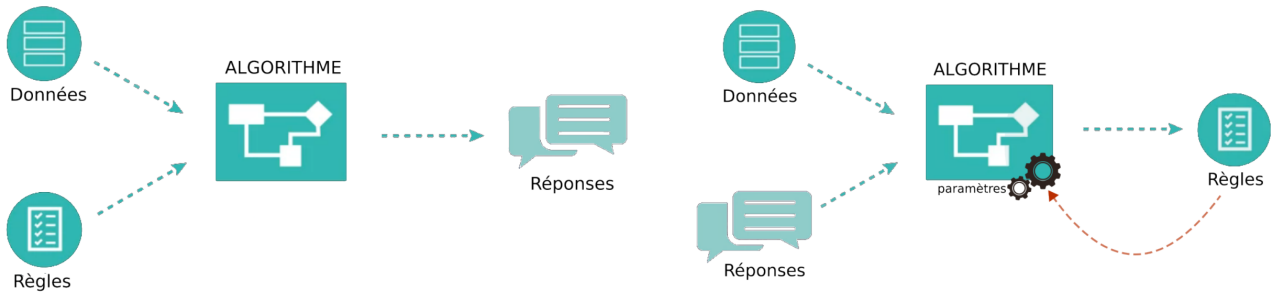

(a) (b)

FIG. 1.2 – (a) Principe d'un algorithme traditionnel. L'algorithme prend en entrée des données et se sert de règles (condition `if`, boucles `for`, fonctions mathématiques, etc.) pour produire une réponse en sortie. (b) Principe de l'apprentissage d'un algorithme d'intelligence artificielle. Lors de la phase d'apprentissage, l'algorithme prend en entrée des données (en grande quantité) et éventuellement des réponses (si les données sont déjà étiquetées) et en déduit des règles (de régression, de classification, etc.). Lors de la phase d'apprentissage, l'algorithme modifie les règles en affiner la valeur des paramètres de l'algorithme.

Exemple 1.1 : Reconnaissance d'images

Un application importante de l'IA est la reconnaissance d'image. On montre ci-dessous une illustration de la phase d'apprentissage automatique d'un algorithme de reconnaissance d'image.

(a) cat (b) cat (c) cat (d) dog (e) dog (f) dog

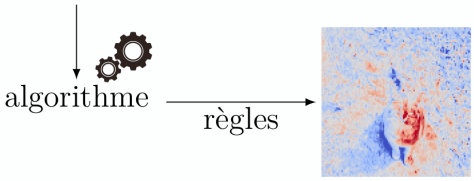

Une fois l'algorithme entraîné, on exige de l'algorithme qu'il puisse fournir une réponse en sortie lorsqu'on lui donne une image inconnue en entrée, comme ci-dessous.

1) S'agit-il d'un problème de régression ou de classification ?
2) S'agit-il d'un apprentissage supervisé ou non supervisé ?

I.B – Algorithmes de classement

Définition 1.3 (Classification)

*On appelle **classification** des données une partition de E, c'est-à-dire une famille de sous-ensembles $E_i \subset E, i = 1, ..., n$:*

- *dont la réunion décrit l'ensemble entier (tous les éléments sont classés) : $\cup_i E_i = E$;*
- *disjoints (un élément n'appartient qu'à une seule classe) : $E_i \cap E_j = \varnothing$ si $i \neq j$.*

Propriété 1.1

*On représente une classification $(E_i)_{i=1,...n}$ sous `python` par un **dictionnaire***

```
p={y1:c1, y2:c2, ..., yN:cN}
```

où les y_j sont les éléments de $E = \cup_i E_i$ et c_j désigne la classe à laquelle appartient y_j (l'un des E_i).

Exemple 1.2 : Reconnaissance d'images

Quelle est la classification des images de l'exemple précédent ? La définir sous `python`.

Exemple 1.3 : Recherche d'articles de presse

On souhaite proposer un algorithme de recherche d'articles de presse suivant leur sujet. On considère 5 particles de presse appartenant à 2 classes : les sujets « culture » et « science ». Les articles sont modélisés par un point $y = (c, s)$ du plan où c représente la fréquence du mot « culture » et s la fréquence du mot « science » dans le corps de l'article.

Articles	Article 1	Article 2	Article 3	Article 4	Article 5
c	0.8	0.2	0.6	0.4	0.9
s	0.5	0.9	0.3	0.7	0.2
Sujet	Culture	Science	Culture	Science	Culture

1) Définir formellement puis en `python` l'ensemble d'apprentissage E.
2) Définir formellement puis en `python` la classification $(E_i)_{i=1,...n}$ associée.

II – Apprentissage supervisé

II.A – Algorithme des k plus proches voisins

Définition 1.4 (Distance)

*Une **distance** est une fonction $d(x, y)$ de deux données x et y de l'ensemble d'apprentissage E.*

Exemple 1.4 : Exemples de distance

1) Pour des points du plan $x = (x_1, x_2)$ et $y = (y_1, y_2)$ définis sur une grille, on peut utiliser la distance de Manhattan, définie par

$$d_{\mathrm{M}}(x, y) = |x_1 - y_1| + |x_2 - y_2|. \tag{1}$$

Justifier le nom donner à cette distance. Que vaut $d_{\mathrm{M}}((1, 2), (3, 4))$?

2) On suppose que les données de E sont des images en niveau de gris. En supposant les couleurs codées sur 8 bits, dans quel ensemble mathématique appartient le niveau de gris $G(x)$ d'un pixel x ? Définir une distance d_{g} qui compare les niveaux de gris des mêmes pixels x et y pris de deux images différentes.

3) On suppose que les données de E sont des chaînes de caractères. On définit la distance de Hamming $d_{\mathrm{H}}(x, y)$ comme le nombre de caractères à modifier pour passer de la chaîne x à la chaîne y. Par exemple, la distance de Hamming entre les mots « ramer » et « cases » vaut 3. Que vaut la distance de Hamming pour : les mots « chanter » et « chat » ; les nombres binaires 0110 et 1110 ?

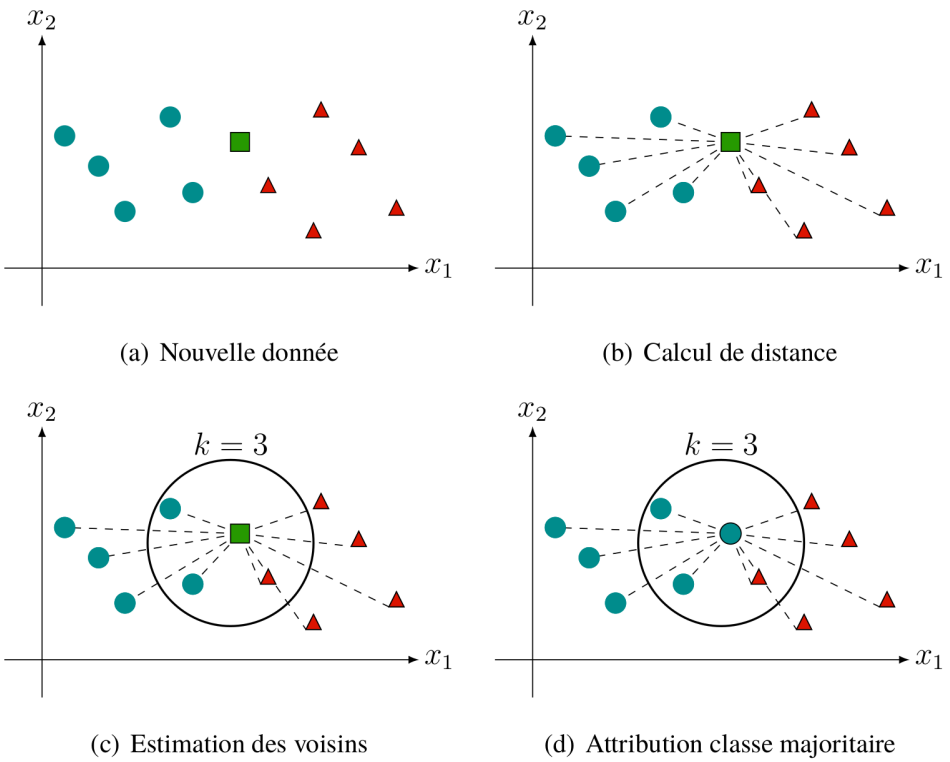

(a) Nouvelle donnée (b) Calcul de distance

(c) Estimation des voisins (d) Attribution classe majoritaire

FIG. 1.3 – Principe de l'algorithme des k plus proches voisins. (a) On considère un ensemble d'apprentissage E contenant N éléments. (b) On souhaite classer un nouvel élément x n'appartenant pas à E. (c) On détermine les k plus proches voisins de x dans E. On associe à x la classe majoritaire des voisins. (d) On associe à x la classe majoritaire des voisins.

Définition 1.5 (Algorithme des k plus proches voisins)

1 *On trie l'ensemble E suivant l'ordre croissant des distances à x, c'est-à-dire la valeur de $d(x, y)$ avec $y \in E$. On obtient une liste à N éléments* $\mathrm{tri}(E, x, d)$.

2 *On choisit les k plus proches voisins, c'est-à-dire les k premiers éléments de* $\mathrm{tri}(E, x, d)$. *On*

obtient la liste voisins(E, x, d, k).

3 *On détermine la classe dominante de* voisins(E, x, d, k), *notée* classemaj(E, x, d, k, p) *c'est-à-dire qu'on détermine la classe i telle que l'intersection $E_j \cap$* voisins(E, x, d, k) *contienne le maximum d'éléments pour $j = i$. On associe ainsi la classe i au nouvel élément x.*

Exemple 1.5 : Recherche d'articles de presse

Reprenons l'exemple de recherche d'articles de presse, Ex. I.B. Un auteur publie un nouvel article sur le site internet du magazine (Article 6) dont la fréquence du mot « culture » est $c = 0.6$ et la fréquence du mot « science » est $s = 0.5$. On souhaite classer cette nouvelle donnée $x = (0.6, 0.5)$ dans l'une des deux classes « culture » ou « science » en s'aidant de l'ensemble d'apprentissage E précédent. On utilise la distance euclidienne.

1) Rappeler la définition de la distance euclidienne dans ce contexte.
2) Déterminer la liste triée des éléments de E suivant l'ordre croissant des distances à x. Représenter l'ensemble des données E et x sur un graphique.
3) Déterminer les $k = 3$ plus proches voisins de x dans E. Représenter les k plus proches voisins sur le graphique. Pourquoi est-il préférable de choisir un nombre impair k de voisins ?
4) Déterminer la classe majoritaire des voisins. En déduire la classe de x.

II.B – Matrice de confusion

Exemple 1.6 : Test médical

Considérons un test médical destiné à déterminer la présence ou non d'une infection chez un groupe de 100 patients. L'efficacité du test n'est pas parfaite. On suppose que 90 prédictions du test sont corrects, tandis que 10 prédictions sont fausses.

- Parmi les tests corrects, 20 sont de vrai positifs, et 70 des vrais négatifs.
- Parmi les tests incorrects, 8 sont de faux négatifs, et 2 des faux positifs.

Représenter les données dans le tableau suivant.

		Classe prédite	
		Infecté	Sain
Classe réelle	Infecté	...	...
	Sain	...	...

Définition 1.6 (Matrice de confusion)

On appelle ***matrice de confusion*** *la matrice M de taille $n \times n$ (avec n le nombre de classes) dont*

- *chaque ligne i correspond à une classe réelle T_i ;*
- *chaque colonne j correspond à une classe prédite T_j ;*
- *chaque élément M_{ij} donne le nombre de données de classe réelle T_i et de classe prédite T_j.*

Exemple 1.7 : Caractéristiques d'un test médical

Considérons le test médical suivant.

		Classe prédite	
		Infecté	Sain
Classe réelle	Infecté	20 (vrai positif)	8 (faux négatif)
	Sain	2 (faux positif)	70 (vrai négatif)

1) Que vaut le nombre de données N ? Que vaut le nombre de données correctes N_c ? Que vaut le nombre de données incorrectes N_i ?
2) Calculer la précision P et le taux d'erreur TE.
3) Calculer le nombre de négatifs n et le nombre de positifs p. En déduire la sensibilité s et la spécificité $\overline{s}$.
4) On définit le taux de négatifs $\mathrm{TN} = \frac{n}{N}$. Trouver une relation littérale entre s, P et TN.

Exemple 1.8 : Implémentation de test de qualité des prédictions

Pour chacune des fonctions ce-dessous, on précisera les spécifications de cette fonction et on la commentera. Tester cette fonction sur un exemple.

1) Définir en `python` une fonction `erreur` qui prend comme seul argument la matrice M *de taille quelconque* et qui calcule le taux d'erreurs du test.
2) Définir en `python` une fonction `sensibilite` qui prend comme seul argument la matrice M de taille 2 par 2 et qui calcule la sensibilité du test.
3) Définir en `python` une fonction `specificite` qui prend comme seul argument la matrice M de taille 2 par 2 et qui calcule la spécificité du test.
4) Définir en `python` une fonction `prevalence` qui prend comme seul argument la matrice M de taille 2 par 2 et qui calcule la prévalence du test, c'est-à-dire le nombre de patients infectées sur le nombre total de patients.

III – Apprentissage non supervisé

III.A – Algorithme des k moyennes

Définition 1.7 (Algorithme des k moyennes)

Soit un ensemble d'apprentissage E, deux entiers $k \geq 1$ et $n_i \geq 1$, et d une distance.

1. *Initialiser aléatoirement les centres c_i parmi les éléments de E pour $i = 1, ..., k$.*
2. *À chaque itération$j = 1, ..., n_i$, effectuer :*
   - *partitionnement de E autour des centres c_i selon la distance d ;*
   - *ré-évaluation des centres c_i comme barycentre du groupe E_i.*

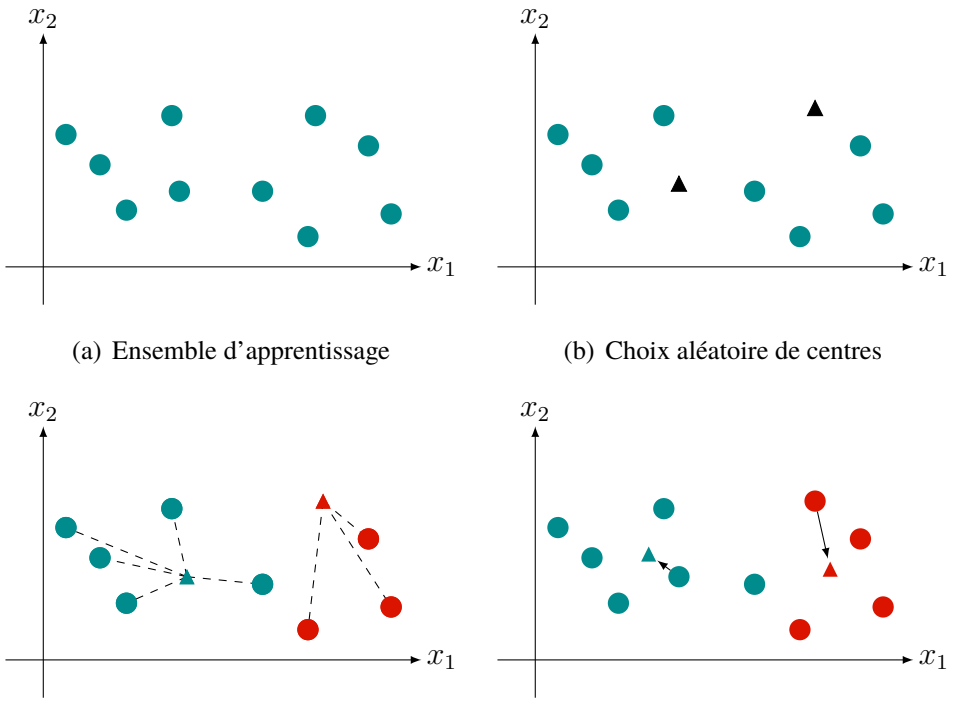

(a) Ensemble d'apprentissage (b) Choix aléatoire de centres

(c) Partitionnement suivant la distance (d) Évaluation des centres comme barycentres

FIG. 1.4 – Principe de l'algorithme des k moyennes. (a) On considère un ensemble d'apprentissage E contenant N éléments. (b) On choisit aléatoirement k centres parmi les données de E. (c) On partitionne E suivant la distance aux centres. (d) On ré-évalue les centres comme barycentre de chaque classe. On réitère ensuite le processus.

Exemple 1.9 : Classement non supervisé d'articles de presse

Des informaticiens travaillant pour un média connu souhaitent élaborer un algorithme de classement des articles de presse pour le site internet du magazine. Ils souhaitent répartir les articles en $k = 5$ thèmes, sans savoir comment les définir. On modélise un article de presse par un point du plan $y = (e, n)$ où $0 \leq e \leq 1$ représente la quantité d'équations dans le texte et $0 \leq n \leq 1$ est la quantité de noms propres. On dispose d'un ensemble d'apprentissage `articles` contenant les $N = 280$ articles de presse.

1) Implémenter la fonction `moy(E, k, d, ni)` qui applique l'algorithme des k-moyennes à un ensemble d'apprentissage E avec une distance d et un nombre d'itérations n_i.
2) On suppose avoir défini la fonction `d` qui calcule la distance euclidienne. On effectue l'appel `moy(articles, 5, d, 10)` et on représente ci-dessous la partition des données à chaque itération. Commenter.

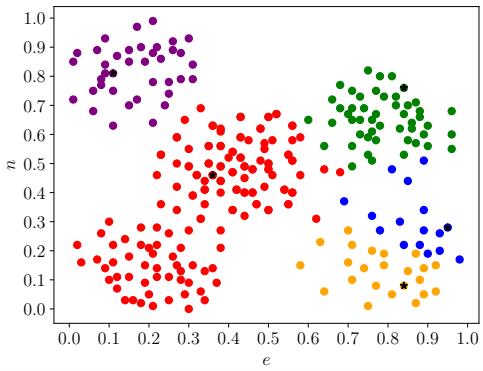

(a) $i = 0$

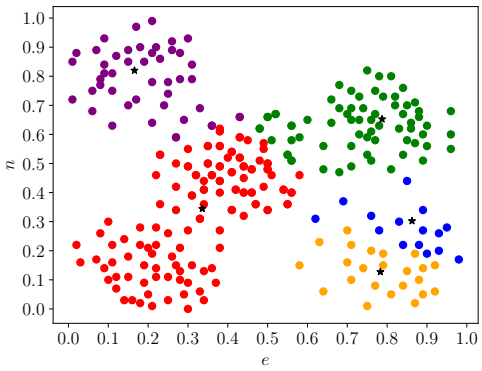

(b) $i = 1$

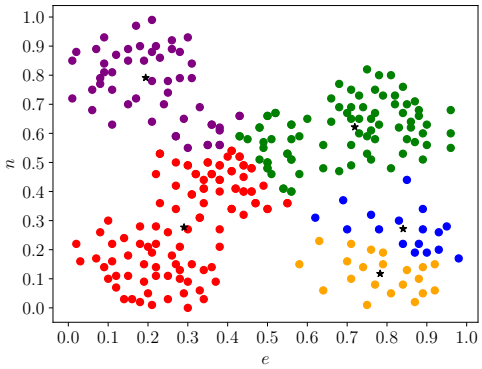

(c) $i = 7$

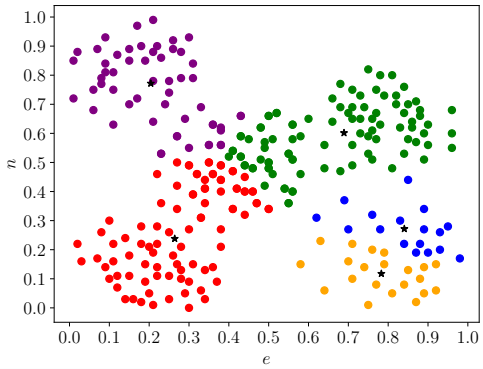

(d) $i = 10$

3) On représente ci-dessous la partition des données pour différentes situations : (a) un autre appel de `moy(articles, 5, d, 10)`, (b) un appel de `moy(articles, 3, d, 10)`. Commenter.

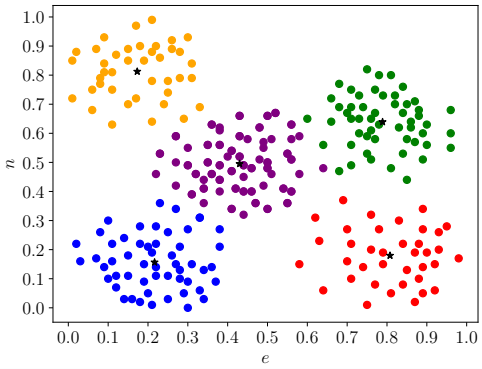

(a)

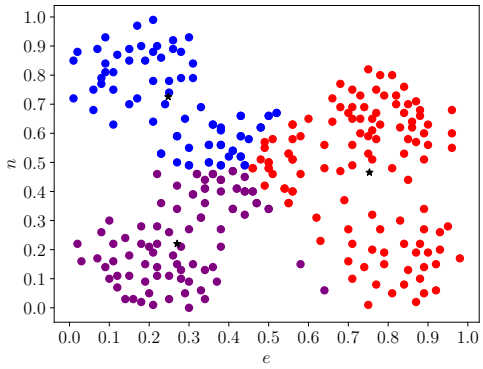

(b)