TD 2

Intelligence artificielle

Exercices

Exercice 1 : Apprentissage supervisé et classement d'articles de presse . . . . . [⋆⋆]

Des informaticiens travaillant pour un média connu souhaitent élaborer un algorithme de classement des articles de presse pour le site internet du magazine. Les articles de presse se répartissent en 5 sujets : sport, politique, science, culture, économie. Pour que l'algorithme soit capable de classer un nouvel article de presse dans l'une de ces 5 classes, on procède par apprentissage supervisé et on recourt à l'algorithme des k plus proches voisins.

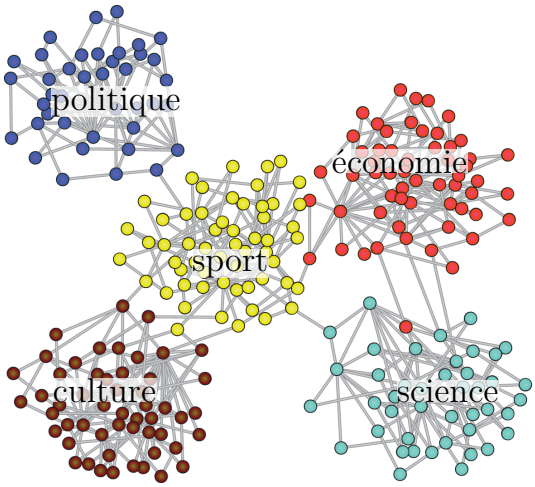

Classification — On dispose d'un ensemble d'apprentissage `articles` contenant les $N = 280$ articles de presse déjà publiés. On souhaite créer une classification des articles de presse selon leur sujet. Pour cela, on modélise un article de presse par un point du plan $y = (e, n)$ où $0 \leq e \leq 1$ représente la quantité d'équations dans le texte et $0 \leq n \leq 1$ est la quantité de noms propres.

1) Rappeler le principe de l'apprentissage supervisé et d'un algorithme de classement.
2) On donne le lien ci-dessous au fichier `article_presse.py` contenant l'ensemble d'apprentissage `articles` (liste de points) et la classification `sujets` (de type dictionnaire). Que vaut `sujets[(0.33, 0.31)]` ?

https://cahier-de-prepa.fr/pc-theo/download?id=682

3) Définir en `python` une fonction distance `d` qui prend comme arguments deux points `y1` et `y2` du plan et qui renvoie la distance euclidienne entre ces deux points.

Phase d'apprentissage : algorithme des k plus proches voisins — On souhaite implémenter puis appliquer l'algorithme des k plus proches voisins pour classer le nouvel article $x = (0.5, 0.6)$. On note de façon générique E un ensemble d'apprentissage, p une classification, k entier le nombre de voisins considérés et d la distance.

4) Rappeler le principe de l'algorithme des k plus proches voisins. Que représentent les fonctions $\text{tri}(E, x, d)$, $\text{voisins}(E, x, d, k)$ et $\text{classe}(E, x, d, k, p)$?
5) On souhaite implémenter la fonction $\text{tri}(E, x, d)$. Rappeler les différents algorithmes de tri usuels. Compléter les lignes de code suivantes pour appliquer le tri bulle à l'ensemble d'apprentissage E. Vérifier cette fonction sur des exemples simples, par exemple pour `E=[(0.1,0.1),(0.9,0.9),(0.5,0.5)]` et `x=(0.4,0.6)`.

```python
def tri(E, x, d):
    """
    Entrée : E (list), x (tuple), d (func)
    Action : tri l'ensemble E selon la distance des points à x
    Sortie : E_tri (list)
    """
    n = len(E)
    E_tri = E
    for i in range(n):
        for j in range(n-i-1):
            if ...
                ...
    return E_tri
```

6) Compléter le code de la fonction voisins(E, x, d, k) définie ci-dessous.

```python
def voisins(E, x, d, k):
    """
    Entrée : E (list), x (tuple), d (func), k (int)
    Action : détermine les k plus proches voisins de x parmi les points de E
    Sortie : k plus proches voisins (list)
    """
    liste = tri(E, x, d) # liste triée (suivant distance d)
    ...                  # à compléter
```

7) On détermine ensuite la classe dominante de voisins(E, x, d, k), c'est-à-dire la classe i telle que l'intersection $E_j \cap$ voisins(E, x, d, k) contienne le maximum d'éléments pour $j = i$. Commenter chaque ligne du code suivant.

```python
def classemaj(E, x, d, k, p):
    """
    Entrée : E (list), x (tuple), d (func), k (int), p (dict)
    Action : détermine la classe majoritaire de x parmi les k plus proches voisins
    Sortie : classe majoritaire (int)
    """
    v = voisins(E, x, d, k)
    c = {p[y]:0 for y in v}
    for y in v:
        c[p[y]] += 1
    maxi = 0
    for i in c:
        if c[i] > maxi:
            maxi, classmaj = c[i], i
    return classmaj
```

Effectuer l'exécution pas à pas de l'appel `classemaj(E, x, d, k, p)` sur l'exemple simple `E=[(0.2,0.2),(0.8,0.8),(0.5,0.5)]`, `p={(0.1,0.1):'culture',(0.9,0.9):'économie',(0.5,0.5):'sport'}`, `k=1` et `x=(0.4,0.6)`.

8) En appelant la fonction `classemaj`, appliquer l'algorithme des k plus proches voisins à l'ensemble d'apprentissage `articles` et à la classification `sujets` pour $x = (0.37, 0.69)$ et $k = 1, 3, 7$. Dans quel sujet classer l'article x ?

Phase de test : matrice de confusion — On considère un ensemble test `articles_test` contenant $N = 20$ articles de presse à publier dont on connaît les sujets, répertoriés dans le dictionnaire `sujets`. On souhaite évaluer la qualité de l'algorithme des k plus proches voisins en calculant la matrice de confusion M associée à cet ensemble test.

9) Rappeler la définition de la matrice de confusion M associée à un ensemble test T de classification p.

10) Créer un dictionnaire `numero` qui associe a chaque classe, de type `string` (chaîne de caractères), un entier de 0 à 4. On donne l'implémentation `python` du calcul de la matrice de confusion ci-dessous. Compléter les lignes manquantes.

```python
def confusion(E, T, d, k, p, n):
    """
    Entrées : E (list), T (list), d (func), k (int), p (dict), n (int)
    Sortie : matrice de confusion M
    """
    M = [[0]*n for l in range(n)]   # initialisation matrice
    for x in T:                     # boucle sur ensemble test
        i = ...                     # classe réelle
        j = ...                     # classe prédite
        M[i][j] += 1                # ajout au compte
    return M                        # retourne matrice de confusion
```

Appliquer cette fonction à l'ensemble test `articles_test` puis inspecter la matrice de confusion.

11) Implémenter les fonctions `precision` et `erreur`. Déterminer la précision P et le taux d'erreur TE.